

# **PENGENALAN TELAPAK TANGAN MENGUNAKAN JARINGAN SIAMESE**

Pendekatan Machine Learning untuk Identifikasi Biometrik

---

Jidan Abdurahman Aufan, 2205422

Jason Suryoatmojo, 2204524

Kelompok 1

Financial Technology, 22 September 2025

# CONTENTS

---

1. Pendahuluan & Tujuan Proyek
2. Metodologi & Alur Kerja
3. Hasil & Eksperimen
4. Kesimpulan

# PENDAHULUAN & TUJUAN PROYEK

---

- Pengenalan biometrik adalah landasan keamanan modern, mulai dari membuka kunci ponsel hingga otorisasi transaksi finansial.
- Sidik telapak tangan menawarkan sumber fitur unik yang kaya, menjadikannya kandidat yang sangat baik untuk identifikasi yang kuat.
- **Tujuan Proyek:** Membangun dan melatih model machine learning yang mampu mengenali individu secara akurat dari gambar telapak tangan mereka, yang diambil menggunakan kamera ponsel.

- Dua dataset utama digunakan untuk melatih dan mengevaluasi model:
  - **Sapienza University Mobile Palmprint Database (SMPD)**
  - **Birjand University Mobile Palmprint Database (BMPD)**
- Kedua dataset ini menyediakan ribuan gambar dari lebih dari 100 subjek, yang menjadi data utama untuk proyek ini.



Figure 1: Contoh gambar telapak tangan dari dataset SMPD.

# METODOLOGI & ALUR KERJA

---

- Pendekatan awal untuk ekstraksi ROI adalah dengan metode *valley-point*. Tujuannya adalah untuk menemukan titik-titik kunci (sela-sela jari) sebagai patokan.
- **Proses Kerja:**
  - Membuat *silhouette* tangan dari image.
  - Mendeteksi *contour* terbesar untuk mengambil bentuk tangan.
  - Mendeteksi *defect* berdasarkan sudut dan posisi untuk memilih kandidat *valley* yang relevan (sela jari).
  - Menetapkan ROI berdasarkan sela jari Kelingking-Manis dan sela jari Telunjuk-Tengah
- **Kelemahan:** Metode ini terbukti **tidak stabil dan sering gagal** (*unreliable*) pada dataset yang digunakan, karena adanya variasi posisi tangan, pencahayaan, juga beberapa tidak menyebarkan jari nya sehingga sela jari sulit dideteksi.

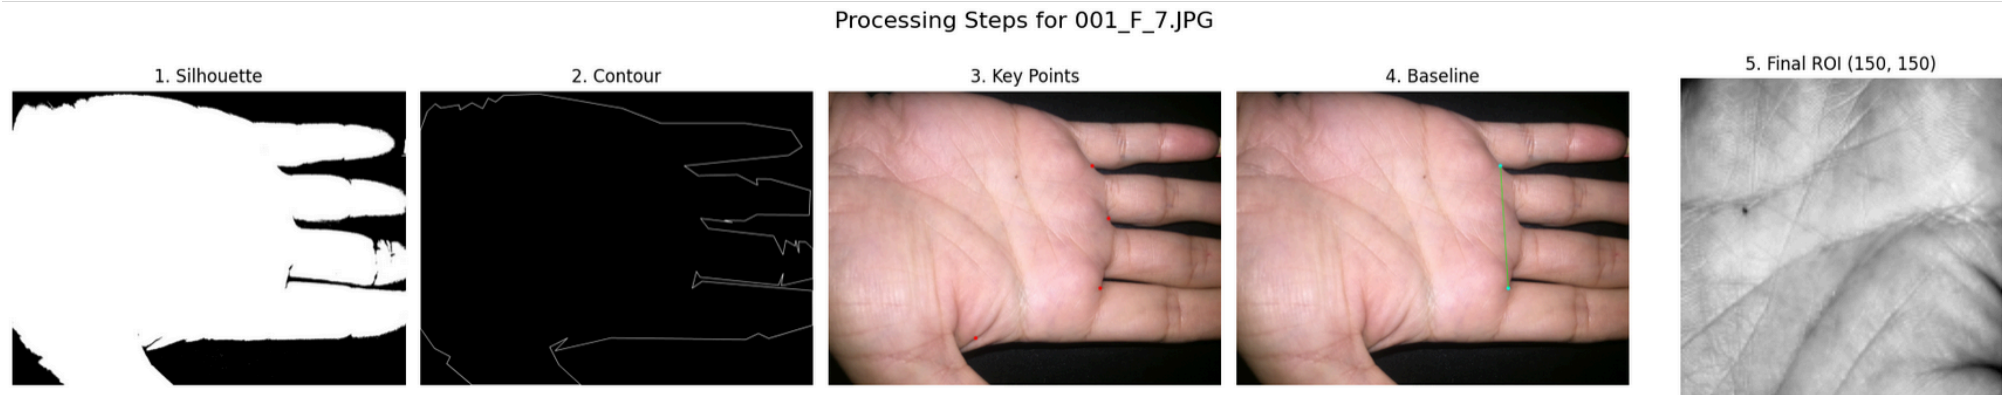


Figure 2: Contoh visualisasi Pendekatan Valley-point.

Visualisasi langkah-langkah pemrosesan: dari **silhouette**, **contour**, deteksi **key points**, **baseline**, hingga ekstraksi **ROI** akhir.



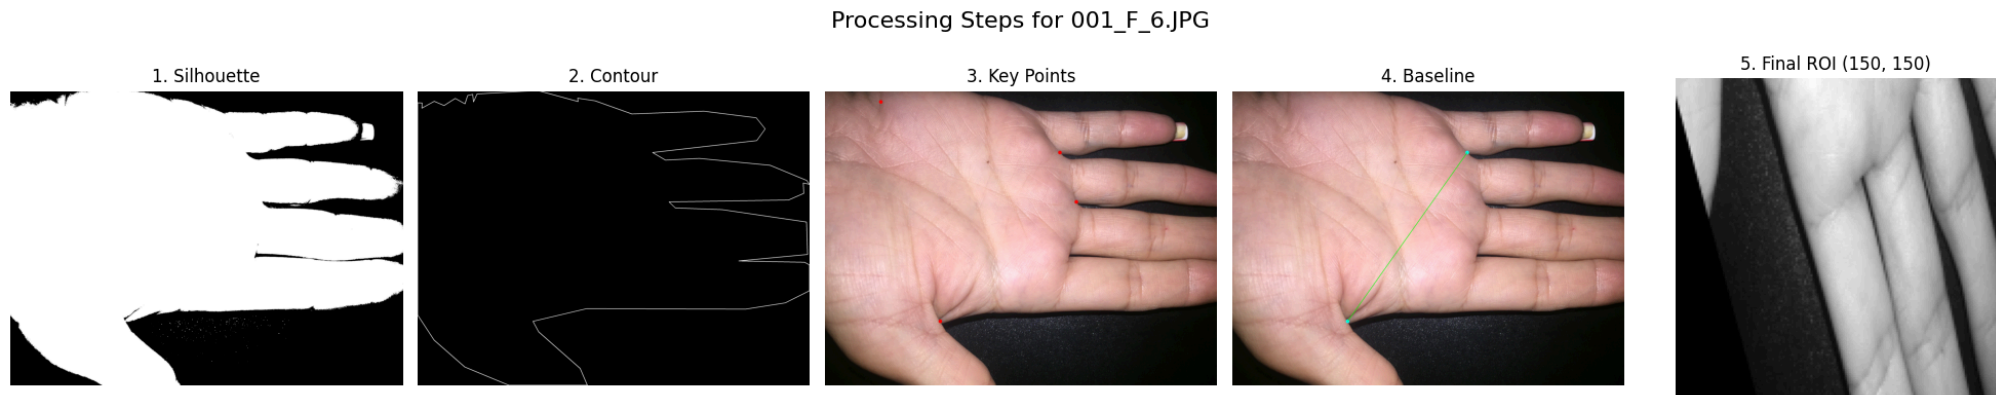


Figure 3: Contoh visualisasi Pendekatan Valley-point gagal.

Karena memilih pasangan point yang jarak nya terjauh, salah memakai point sela ibu jari.

- Karena metode *valley-point* tidak stabil, pendekatan yang lebih robust dan konsisten digunakan.
- Metode ini berfokus pada titik pusat (centroid) dari kontur telapak tangan untuk ekstraksi langsung.
- **Proses Kerja:**
  - Menemukan kontur tangan yang bersih.
  - Menghitung titik pusat geometris (centroid) dari kontur.
  - Memotong area besar (misalnya, 1000x1000 piksel) yang berpusat pada centroid.
  - Menormalisasi ukuran ROI ke dimensi standar yang dibutuhkan model (150x150).

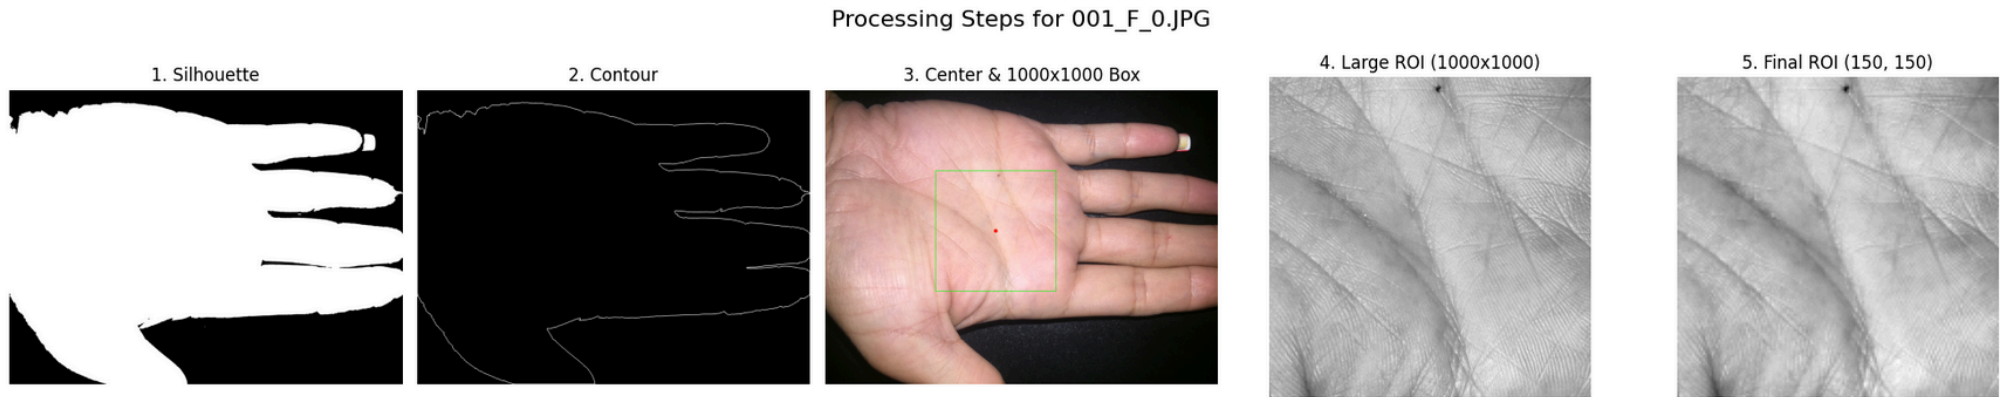


Figure 4: Contoh visualisasi pendekatan centroid

Visualisasi untuk metode berbasis **centroid**, yang terbukti lebih stabil dalam menemukan area telapak tangan.

- **Jaringan Siamese** digunakan karena ideal untuk tugas pengenalan.
- Arsitektur ini menggunakan dua “jaringan dasar” yang identik dan berbagi bobot (*weights*).
- Setiap jaringan mengubah gambar menjadi sebuah **vektor fitur** (embedding) numerik.
- Tujuan model adalah untuk mempelajari ruang fitur di mana vektor dari **orang yang sama** menjadi berdekatan, dan vektor dari **orang yang berbeda** menjadi berjauhan.

- **Fungsi Loss:** Model dilatih menggunakan **Loss Kontrastif** (*Contrastive Loss*). Fungsi ini “memaksa” model untuk:
  - **Meminimalkan** jarak Euclidean untuk pasangan positif (orang yang sama).
  - **Memaksimalkan** jarak untuk pasangan negatif (orang yang berbeda).
- **Persiapan Data:** Set pelatihan diubah menjadi ribuan pasangan positif dan negatif yang dibuat secara acak.
- **Evaluasi:** Kinerja model diukur dari kemampuannya mengidentifikasi gambar “probe” dengan mencari padanan terdekat dalam “galeri” pengguna yang sudah terdaftar.

# HASIL & EKSPERIMEN

---

- Pelatihan model dasar menunjukkan tren pembelajaran yang sangat baik, di mana **training loss** dan **validation loss** sama-sama menurun secara konsisten.
- Namun, seiring berjalannya epoch, mulai terlihat celah (*gap*) di antara kedua kurva. **Validation loss** mulai stagnan sementara **training loss** terus anjlok.
- Ini adalah indikasi klasik dari **overfitting**: model mulai terlalu menghafal data latih dan kehilangan kemampuan untuk generalisasi pada data baru.

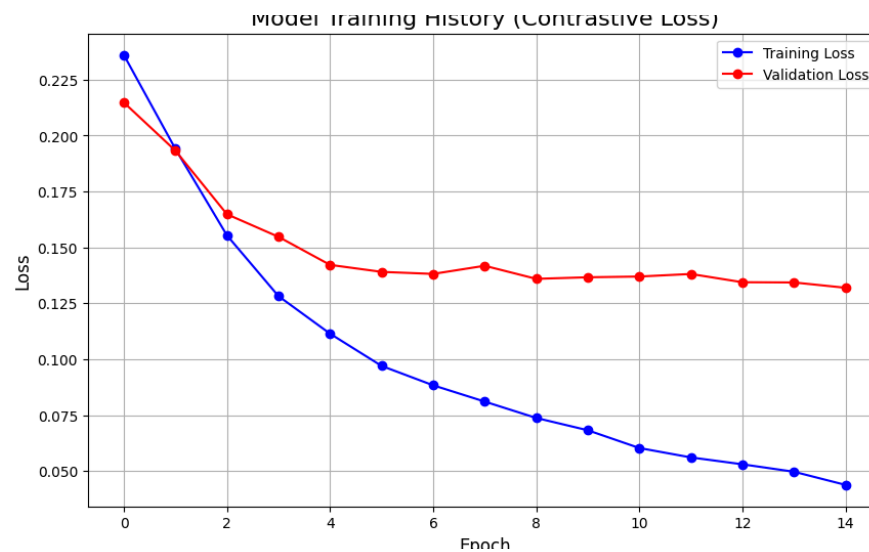


Figure 5: Riwayat Pelatihan Model Dasar

- Hasil ini mendorong perlunya perbaikan untuk meningkatkan regularisasi dan kemampuan generalisasi model.



- Sebuah model dasar dilatih menggunakan arsitektur CNN sederhana dan set pasangan data yang dibuat di awal (*pre-generated*).
- Hasil menunjukkan bahwa model dapat belajar, namun kinerjanya masih rendah.
- - Akurasi Keseluruhan: 32%**
  - Weighted F1-Score: 0.30**
- Laporan menunjukkan varians yang tinggi: beberapa subjek dikenali dengan sempurna, sementara banyak subjek lainnya gagal dikenali sama sekali.

Distance: 0.3898 | Verdict: Correct Identification (✅)

Probe Image  
(True ID: 004)



Closest Match in Database  
(Predicted ID: 004)





Figure 6: Contoh Prediksi Berhasil

Distance: 1.1120 | Verdict: Rejected as Unknown (⚠️)

Probe Image  
(True ID: 002)



Closest Match in Database  
(Predicted ID: 005)




Figure 7: Contoh Prediksi Gagal

Beberapa eksperimen dilakukan untuk meningkatkan kinerja:

1. **Generator Data Dinamis:** Mengganti daftar pasangan statis dengan generator data yang membuat pasangan baru secara acak dan *on-the-fly* untuk setiap *batch*.
2. **Arsitektur yang Ditingkatkan:** Memperkenalkan model V2 yang lebih dalam dengan BatchNormalization untuk stabilitas dan Dropout untuk regularisasi.
3. **Augmentasi Data:** Menambahkan transformasi acak seperti *flip* dan rotasi pada gambar pelatihan untuk menciptakan lebih banyak variasi data.

- Model V2 dilatih menggunakan arsitektur CNN yang lebih dalam, augmentasi data, dan generator data dinamis.
- Hasil menunjukkan model dapat belajar dari data latih, namun kinerja generalisasinya secara keseluruhan masih rendah.
- - Akurasi Keseluruhan: 32%**
  - Weighted F1-Score: 0.31**
- Laporan klasifikasi menunjukkan varians yang sangat tinggi: beberapa subjek dikenali dengan baik ( $F1 > 0.7$ ), sementara banyak subjek lainnya gagal dikenali sama sekali ( $F1 = 0.00$ ).

- Untuk mengatasi **overfitting** pada model dasar, model V2 dilatih dengan tugas yang jauh lebih sulit, menggunakan augmentasi dan generator data dinamis.
- Pelatihan berjalan **stabil** dan tidak mengalami *loss* yang meledak. Nilai *loss* secara umum lebih tinggi, yang wajar terjadi karena variasi data latih yang jauh lebih besar.
- Meskipun kinerja sedikit meningkat, **validation loss** yang stagnan menunjukkan bahwa tantangan utama tetap pada kualitas dan konsistensi data ROI itu sendiri.

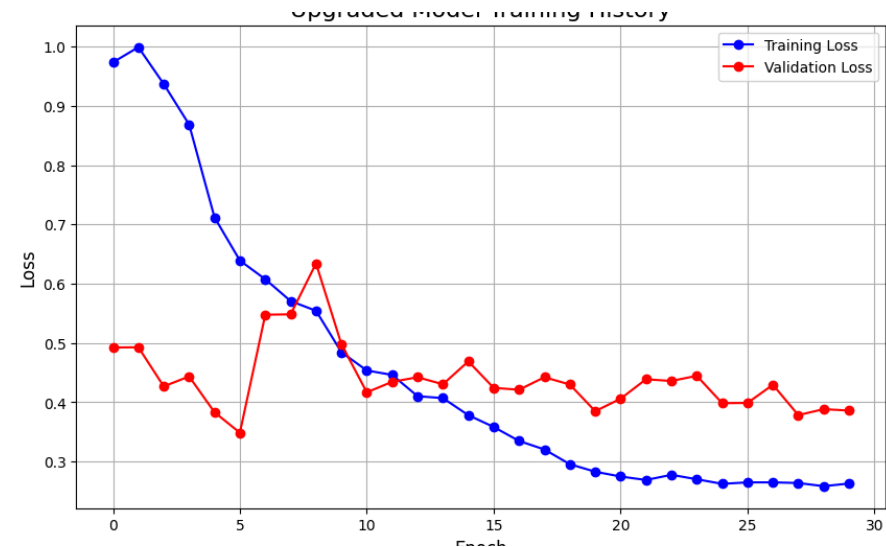


Figure 8: Riwayat Pelatihan Model V2  
(Stabil)

- Meskipun arsitektur model selalu dapat dioptimalkan, hasil pelatihan menyoroti sebuah tantangan yang jelas: kinerja model apapun sangat bergantung pada kualitas data training. Kemungkinan besar, kinerja model kini lebih dibatasi oleh kualitas dan konsistensi data dan Region of Interest (ROI) yang diekstrak.
- Beberapa tantangan utama dalam tahap *preprocessing* teridentifikasi:
  - **Kontur yang Tidak Sempurna:** Pencahayaan yang tidak konsisten pada dataset menghasilkan siluet dengan pinggiran yang tajam, terutama di area pergelangan tangan. Hal ini menciptakan *convexity defects* palsu yang sering keliru dideteksi sebagai lembah jari oleh algoritma.
  - **Kesulitan Identifikasi Lembah Jari:** Sangat sulit untuk merancang aturan geometris yang dapat secara konsisten membedakan empat lembah jari utama dari lembah ibu jari yang

dalam, terutama pada gambar di mana jari-jari tidak terentang sempurna. Hal ini sering menyebabkan pemilihan titik acuan ROI yang salah.

- **Keterbatasan Aturan Geometris:** Solusi yang lebih andal memerlukan peralihan dari aturan geometris ke metode yang lebih cerdas seperti *deteksi landmark*. Dengan melatih model untuk mengenali setiap lembah secara spesifik (misalnya, “lembah telunjuk-tengah”), kita dapat menerapkan strategi ekstraksi ROI yang berbeda dan lebih akurat, sesuai dengan pasangan titik acuan yang berhasil diidentifikasi.

# KESIMPULAN

---



## Kesimpulan:

- Alur kerja *end-to-end* untuk pengenalan telapak tangan berhasil dibangun, mulai dari pra-pemrosesan data hingga pelatihan dan evaluasi Jaringan Siamese.
- Metode ekstraksi ROI berbasis **centroid** terbukti **andal dan konsisten** untuk data yang bervariasi, meskipun metode berbasis **valley-point** secara teoretis lebih presisi secara anatomis.
- Peningkatan arsitektur ke model V2 berhasil mengatasi **overfitting**, namun kinerja akhir tetap terbatas (akurasi 32%), yang mengindikasikan bahwa **kualitas ROI** adalah faktor pembatas utama saat ini.

## Saran Pengembangan:

- **Membangun Dataset Baru:** Membuat dataset baru dengan kondisi yang terkontrol (pencahayaannya seragam, pose tangan konsisten) untuk memastikan data cocok dan andal bagi metode ekstraksi ROI yang lebih presisi seperti *valley-point*.
- Fokus utama adalah mengembangkan metode ekstraksi ROI hibrida yang menggabungkan **keandalan pendekatan centroid** dengan **presisi anatomis pendekatan valley-point**.
- Mengimplementasikan model **deteksi landmark** untuk mengenali setiap lembah jari secara spesifik adalah langkah paling menjanjikan untuk mencapai tujuan tersebut dan meningkatkan kualitas ROI secara signifikan.
- Melakukan *hyperparameter tuning* lebih lanjut pada arsitektur V2, termasuk optimasi `learning rate` dan `recognition_threshold` untuk memaksimalkan potensi model dengan data ROI yang lebih baik.

Terima Kasih  
Ada Pertanyaan?